

Experimentos de Regularización en un Modelo Neuronal

Tarea 3 – Aprendizaje Automático

David Luna

1 Introducción

El objetivo de esta tarea es comparar diferentes técnicas de regularización en un modelo neuronal simple usando el dataset MNIST. Se realizaron 5 experimentos:

1. Baseline (sin regular)
2. Regularización L1
3. Regularización L2
4. Dropout
5. Batch Normalization

Cada experimento se entrenó con las mismas condiciones (épocas, batch size, optimizador) para evaluar únicamente el efecto de la regularización.

2 Arquitectura del Modelo

La arquitectura común fue:

- Entrada: 28x28 flatten
- Capa densa de 128 neuronas, ReLU
- Capa densa de 10 neuronas softmax

El optimizador utilizado fue Adam y la función de pérdida.

3 Descripción de los 5 Experimentos

3.1 Experimento 1: Baseline

- Sin regularización
- Precisión final: **ACC = 0.9758**
- Pérdida final: **Loss = 0.1650**

3.2 Experimento 2: Regularización L1

Se agrega regularización L1 al kernel de la capa densa:

$$L1(\theta) = \lambda \sum_i |\theta_i|$$

- Valor usado: $\lambda = 1e^{-4}$
- Precisión final: **ACC = 0.9743**
- Pérdida final: **Loss = 0.1998**
- Observación: produce pesos más dispersos y una pérdida algo mas grande.

3.3 Experimento 3: Regularización L2

La regularización L2 penaliza la magnitud de los pesos:

$$L2(\theta) = \lambda \sum_i \theta_i^2$$

- Valor usado: $\lambda = 1e^{-4}$
- Precisión final: **ACC = 0.9693**
- Pérdida final: **Loss = 0.1517**
- Observación: suele ser más estable que L1.

3.4 Experimento 4: Dropout

El dropout desactiva aleatoriamente neuronas durante el entrenamiento:

- Dropout rate: 0.3
- Precisión final: **ACC = 0.9745**
- Pérdida final: **Loss = 0.0944**

3.5 Experimento 5: Dropout + L1-L2

BN normaliza las activaciones en cada batch, acelerando el aprendizaje.

- Precisión final: **ACC = 0.9744**
- Pérdida final: **Loss = 0.1677**
- Observación: reduce covariate shift.

4 Tabla comparativa

Experimento	Accuracy	Loss
Baseline	0.9758	0.1650
L1	0.9743	0.1998
L2	0.9693	0.1517
Dropout	0.9745	0.0944
Dr + L1-L2	0.9744	0.1677

5 Conclusiones

- L1 le pega más fuerte, lo cual reduce overfitting pero también baja algo precisión.
- L2 es más suave y normalmente mejora la estabilidad si la comparas con L1.
- Dropout funciona bien en redes profundas; aquí ayuda pero no la verdad no mucho.
- Dr + L1-L2 suele ser la mejor regularización ligera y estable.

En este caso, el mejor rendimiento se obtuvo con **Dropout**, mientras que L1 fue el más agresivo y redujo la precisión del modelo.